

K-recursion Gaussian BN: 応用実験サマリー

隠れノード推定・センサー配置・介入の情報幾何・構造学習

自動生成 (experiments/make_summary.py より)


2026 年 6 月 10 日

概要

`gaussian_bn` ライブラリを用いた 3 つの応用実験の**実行結果**である。全数値は各 `run` スクリプトが出力した `results/exp{1,2,3}.json` から機械転記しており、合成データは含まない。乱数シードは 20260610。実験はノート of Experiment 2-4 と Theme D に対応する。

1 実験 1: 隠れノード推定 — EM と勾配学習の比較

diamond DAG ($0 \rightarrow 1, 0 \rightarrow 2, 1 \rightarrow 3, 2 \rightarrow 3$) の中間 $\{1, 2\}$ を hidden とし、観測 $\mathcal{O} = \{0, 3\}$ ($N = 200000$)。観測周辺尤度 $\mathcal{L} = \log \det K_{\mathcal{O}\mathcal{O}} + \text{tr}(K_{\mathcal{O}\mathcal{O}}^{-1} S)$ を EM・Adam・LBFGS で最小化した。




手法	最終 NLL	$\ K_{\mathcal{O}\mathcal{O}}(\hat{\eta}) - S\ /\ S\ $	反復	時間 [s]
EM	2.203	2.327×10^{-15}	60	0.220
Adam	2.203	4.880×10^{-10}	400	1.337
LBFGS	2.203	1.696×10^{-9}	9	0.023

NLL の理論最適値は $\log \det S + \dim = 2.203$ で、3 手法すべてが到達した（観測共分散を標本共分散へ復元）。

■**gauge 診断**. 解での 4 edge 母数の Fisher 固有値は $\{-2.541 \times 10^{-16}, 1.863 \times 10^{-16}, 0.280, 0.965\}$ 、 $\text{rank } G^{(\mathcal{O})} = 2 < q = 4$ 。零空間は 2 次元で、2 つの hidden ノードのスケール gauge に対応する（観測共分散は復元できても edge 母数自体は識別不能）。

2 実験 2: センサー配置と edge 識別可能性

6 ノード DAG の 6 本の edge 母数に対し、観測ノード集合 $\mathcal{O}$ を予算 m 以内で選ぶ。pullback Fisher 計量 $G^{(\mathcal{O})}$ の D 最適 $\log \det(G^{(\mathcal{O})} + \epsilon I)$ を greedy 最大化し、各予算での識別 rank と最小固有値も記録した。




m	選択ノード	$\log \det G$	$\lambda_{\min}$	rank
1	[5]	-102.840	1.000×10^{-9}	1/6
2	[5, 3]	-60.549	1.000×10^{-9}	3/6
3	[5, 3, 2]	-1.997	0.051	6/6
4	[5, 3, 2, 1]	1.938	0.324	6/6
5	[5, 3, 2, 1, 4]	4.961	0.855	6/6
6	[5, 3, 2, 1, 4, 0]	6.230	1.650	6/6

わずか 3 ノードの観測で全 6 edge が識別可能 (rank = 6) になり、以降はセンサー追加で条件数 ($\log \det G$, $\lambda_{\min}$) が改善する。

■greedy vs exhaustive (予算 3). D 最適では greedy [5, 3, 2] と exhaustive [2, 3, 5] が一致 (スコア -1.997)。一方 E 最適 ($\max \lambda_{\min}$) は greedy [0, 1, 2] (1.000×10^{-9}) が exhaustive [1, 4, 5] (0.066) に劣る。これは E 最適性が劣モジュラでないための既知の挙動で、rank 不足の領域では greedy が停滞する (exhaustive か rank 考慮基準が必要)。

3 実験 3: 介入の情報幾何

交絡三角形 $0 \rightarrow 1$, $0 \rightarrow 2$, $1 \rightarrow 2$ (ノード 0 は隠れ交絡、 $1 \rightarrow 2$ が直接効果 c)。観測上の連関 $I(V_1; V_2)$ は交絡経路と直接経路の混合だが、hard 介入 $\text{do}(V_1)$ はノード 1 を親から切り離すため $I^{\text{do}}(V_1; V_2)$ は直接因果効果のみを表す。差 $\Delta I = I(V_1; V_2) - I^{\text{do}}(V_1; V_2)$ が交絡 (非因果) 成分である。



設定	$I(V_1; V_2)$	$I^{\text{do}}(V_1; V_2)$	交絡成分 ΔI
$c = 0$ (交絡のみ)	0.378	0	0.378
$c = 0.9$ (交絡 + 直接)	0.874	0.077	0.797


$c = 0$ では観測連関があるのに $I^{\text{do}} = 0$ (連関は完全に交絡由来；介入で $\text{Cov}(V_1, V_2)$ も 0)。 c が増えたと I^{do} が直接因果効果として立ち上がり、観測連関との差が交絡成分を与える。do 演算が因果と交絡を情報量で分離できる。

4 実験 5: 構造学習 (group sparsity による枝刈り)

全結合 supergraph ($i < j$ の全 10 本) から出発し、5 ノード (各 2 次元) の BN を K-recursion 周辺尤度 + **group sparsity** で学習：

$$\min_{\eta} \mathcal{L}(\eta) + \lambda \sum_{(i,j)} \|A_{ji}\|_F \quad (1)$$

を近接勾配 (平滑勾配ステップ + edge ブロックの group soft-threshold) で解く。 λ を上げると不要 edge の 2×2 ブロックが丸ごと 0 に潰れる。各 λ の選択構造を無罰則 MLE (`fit_local_regression`) で再フィットし BIC で構造選択した。



λ	再フィット NLL	BIC	edge 数	選択
0	3.071	1557.856	10	
1.000	3.140	1465.588	5	←
2.000	7.397	3072.541	1	
4.000	8.539	3505.622	0	
7.000	8.539	3505.622	0	

$\lambda = 0$ (罰則なし MLE) は全 10 本を残して過適合するが、 $\lambda = 1.000$ で偽 edge の 2×2 ブロックが正確に 0 となり、BIC が真の構造を選択。完全復元 (TP=5, FP=0, FN=0, precision = 1.000, recall = 1.000)。全観測のため再フィットは局所回帰の閉形式 MLE で行えるが、同じ枠組みは観測集合を変えるだけで hidden node にも拡張できる。

5 まとめ

- **実験 1:** 隠れノードありでも EM/Adam/LBFGS が同一最適 NLL に到達し観測共分散を復元、Fisher rank が latent gauge を正しく検出。
- **実験 2:** Fisher 情報に基づく D 最適 greedy センサー配置で、少数観測でも全 edge を識別可能にできる。E 最適は劣モジュラでないため greedy の限界も定量的に確認。
- **実験 3:** do 演算により観測連関を因果（直接）成分と交絡成分へ情報量で分解。
- **実験 5:** supergraph から group sparsity 近接勾配で枝刈りし、再フィット + BIC で真の DAG 構造を完全復元（構造学習への入口）。
- いずれも `gaussian_bn` の単一 API (K-recursion・推論・訓練・Fisher・介入・設計) 上で完結し、全数値は実行結果ファイル由来である。